

به نام خدا



## گزارش پروژه بینایی علوم اعصاب

حسین ابراهیمی - ۹۵۱۰۵۳۰۲

مدرس : دکتر علی قاضی زاده

---

### قسمت اول: آشنایی با مقاله پژوهشی اصلی

۱.

در این مقاله قصد شده است که ویژگی‌های تحریک‌کننده‌های بینایی را شناسایی کنیم که باعث فعالیت‌های نورون‌های پیچیده در primary visual cortex گره می‌شود (یا به عبارتی دیگر با نشان دادن این تحریک‌کننده‌ها به نورون مربوطه، فعالیت‌های spiking آن افزایش می‌یابد). بدین منظور مجموعه‌ای از stimulus ها را به گره نشان می‌دهیم و سپس با استفاده از تکنیک‌های آنالیزی که از قبل بررسی شده‌اند مانند Independent Component Analysis ، Principle Component Analysis و یا andOr آنالیز، مجموعه پایه‌ای برای ویژگی‌های تحریک‌کننده می‌سازیم. دقت کنیم که روش Spike Trigger Average کار مشابه‌ای را برای وقتی که رابطه پاسخ با تحریک خطی است، انجام می‌دهد (نورون‌های ابتدای visual pathway) اما روشی که در مقاله استفاده شده است روش Correlation Analysis است. چنین مجموعه‌ی پایه‌ای شامل ویژگی‌های مربوطی است که نورون بشدت به آن پاسخ می‌دهد و ویژگی‌هایی نامربوطی است که باعث ایجاد spike در نورون نمی‌شود. ویژگی‌های مربوطه باعث بیشتر شدن نرخ firing می‌شود و ویژگی‌های نامربوط به نورون خاص را suppress می‌کند به شکلی آن‌ها ربطی به spiking ندارند. و میزان همکاری آن‌ها مهم نیست.

۲.

با توجه به متن مقاله نورون‌های پیچیده، نورون‌هایی تعریف شده‌اند که در مقابل تحریک رفتاری غیرخطی از خود نشان می‌دهند و بیشتر نورون‌های بینایی در قسمت visual cortex را این نورون‌ها تشکیل می‌دهند. این نورون‌ها در مقابل نورون‌های cortex

primary visual قرار دارند که در مقابل تحریک رفتار خطی دارند و بدست آوردن مجموعه پایه برای آن‌ها از طریق STA ممکن است.

### ۳.

visual stimuli ای که موجب اسپایک در نورونها شده‌اند، توزیع متفاوتی از توزیع کل تحریک (تحریک‌های کنترل) خواهد داشت که این تفاوت در توزیع منجر به تفاوت در میانگین، واریانس یا به صورت کلی در ممان‌های آن می‌شود. مقاله در اینجا قصد دارد از روش spike trigger correlation استفاده کند زیرا که روش‌های مانند PCA معمولاً وقتی استفاده می‌شوند که ما به دنبال مولفه‌ها و همچنین ویژگی‌هایی هستیم که بیشترین واریانس را ایجاد می‌کنند ولی قصد ما در اینجا ساختن مجموعه‌ی پایه یا به عبارتی دیگر پیدا کردن ویژگی‌های "مربوط" و "نامربوط" است.

حال ماتریسی با رابطه برای درایه‌هایش که به صورت  $\frac{1}{N} \sum_{i=1}^N S_m(i) S_n(i)$  روی تحریک تعریف می‌شود، بدست می‌آوریم همان correlation matrix می‌باشد. ماتریسی که پیش از این ساختیم ماتریسی بود که بر اساس زمان‌های اسپایک نورون ساخته شده بود. حال برای آنکه معنادار بودن این ماتریس را بسنجیم، نیاز داریم که ماتریسی تصادفی داشته باشیم که لزوماً بر اساس زمان‌های اسپایک نورون بوجود نیامده باشد و رندوم تولید شده باشد. ساختن ماتریس کنترل هم همانند ساختن ماتریس correlation است و تعداد همان  $N$  است، اما دیگر تحریک تصویری ورودی براساس اسپایک نورون انتخاب نمی‌شود و بر اساس یک عدد رندوم، تحریک موردنظر مشخص می‌شود و ماتریس کنترل شکل می‌گیرد.

### ۴.

مقاله برای بررسی اینکه داده‌ها به صورت معناداری با هم متفاوت‌اند ابتدا تعدادی ماتریس کنترل ایجاد می‌کند (منظور همان تحریک‌های کلی و مستقل است). حال بر اساس این ماتریس‌ها بازه‌ی اطمینانی بدست می‌آورد و سپس مقادیر و بردارهای ویژه ماتریس correlation را محاسبه می‌کند. مقادیر ویژه‌ای که با بازه‌ی اطمینان به صورت معناداری متفاوت‌اند، بردار ویژه‌شان همان ویژگی‌هایی است که در مقاله به دنبال بدست آوردن آن برای نورون‌های پیچیده بودیم.

### ۵.

آزمایش انجام شده بدین صورت بوده است که هر stimulus شامل ۱۶ نوار بوده که هر کدام می‌توانستند سیاه و یا سفید باشند و این نوارهای متفاوت در ۱۶ فریم به گره نمایش داده شده‌اند. حال از بین این تحریک‌کننده‌ها دسته‌ای باعث زدن spike در نورون مربوطه می‌شوند. برای بدست آوردن ویژگی‌های مربوط به این دسته، یک روش بدست آوردن میانگین آن‌ها است که همان روش STA است. روش دیگر که بر اساس بردارهای ویژه ماتریس کرولیشن است که برای مقادیر مختلف واریانس در دنباله‌ی تحریک نیز به درستی کار می‌کند و به صورت مستقیم ویژگی‌هایی که باعث firing در نورون شده است که همان بردارهای ویژه هستند را بدست می‌آورد. این بردارهای ویژه وابسته به ماتریس کرولیشن بر اساس بزرگی مقدار ویژه خود معنا دار خواهند بود بدین صورت که هرچه به بردار ویژه‌هایی با مقادیر ویژه بیشتر پیش می‌رویم از significance ویژگی‌ای که بردار ویژه بیان می‌کند کاسته می‌شود. به همین دلیل از ۲ بردار ویژه با بزرگترین مقادیر ویژه استفاده شده است. از بین ۶۰ نورون بررسی شده، ۴۷ تا از آنها دارای ۲ مقدار ویژه در بازه اطمینان بودند که این بردارها دو ناحیه‌ی on-off مربوط به RF را مشخص می‌کنند. حال اگر تابع gabor را fit کنیم خواهیم دید که این دو بردار ویژگی‌هایی با پارامتر مکانی یکسان ولی با ۹۰ درجه تفاوت در فاز را تشخیص می‌دهند که این تفاوت فاز بدلیل رفتار نورون‌های پیچیده است. در ۳ ماتریس کرولیشن ۱ بردار ویژه معنادار بدست آمد که نشان‌دهنده یک RF ساده است ولی در بقیه بیش از ۱ بردار. در این بردارها فقط دو بردار اول ویژگی‌ی معنا داری را مشخص می‌کردند.

## قسمت دوم: آشنایی با دیتاست

۱.

با استفاده از تابع `fget_spk.m` می‌توان هدر فایل‌های `.s0` را بدست آورد. بدین منظور از دستور زیر استفاده می‌کنیم:


```
[a,b] = fget_spk("Address/000413.b03bmsq1D.sa0","header")
```

که خروجی فایل header آن به شکل زیر است:

b.FileInfo		b.DataInfo	
Field ▲	Value	Field ▲	Value
Type	'DAN_SPK'	ID	'b03bmsq1D'
Version	'1.0'	DataFrom	'000413.b03bms...
Fname	'000413.b03bms...	Channel	0
Creator	'f21mlv.vi'	SampleRate	10000
Time	'2000,4,13,11,43...	Gain	10000
		DAQMode	0
		DAQResolution	0
		DataType	0
		DataUnit	0
		TimeMode	0
		TimeOffset	0
		ThreshPeakHigh	5677
		ThreshPeakLow	34749
		ThreshValleyHi...	-44140
		ThreshValleyLow	-20193
		ThreshWidthMax	-19
		ThreshWidthMin	506

۲.

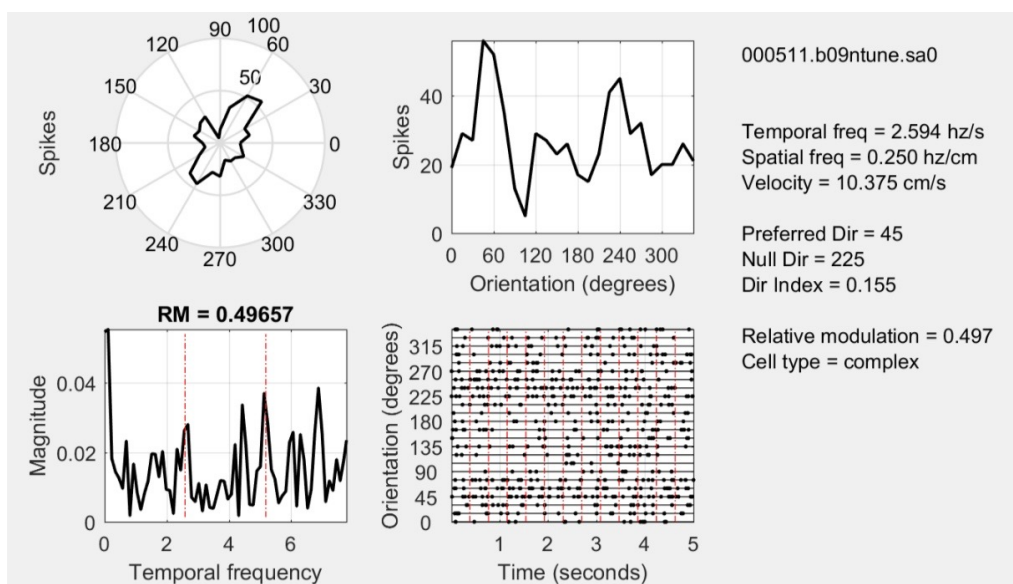
جواب خواسته شده را ابتدا با کدی که در کنار این فایل با نام `Func_ReadData` قرار دارد بدست آمد اما بدلیل تسلط کم بروی متلب، data نرونها را با استفاده از همان تابع `fget_spk.m` در متلب بدست آوردم و سپس آن را با فرمت `.csv` ذخیره کردم و در پایتون از این فایل‌ها استفاده کردم. کد `textstudio.m` که با آن فایل‌های `.csv` بدست آمد پیوست شده است.



تصویر بالا هیستوگرام مربوط به spike-count-rate نورون‌ها است که محور افقی کد مربوط به نورون‌ها است که به دلیل طولانی بودن به درستی مشخص نشده است. نورون‌هایی که spike-count-rate کم‌تر از ۲ دارند:

[000420, 000413, 000524, 000720, 010801, 000907, 000418, 020213, 000412, 011025]

در کد پایتون فرستاده شده با همین نام قرار دارد.

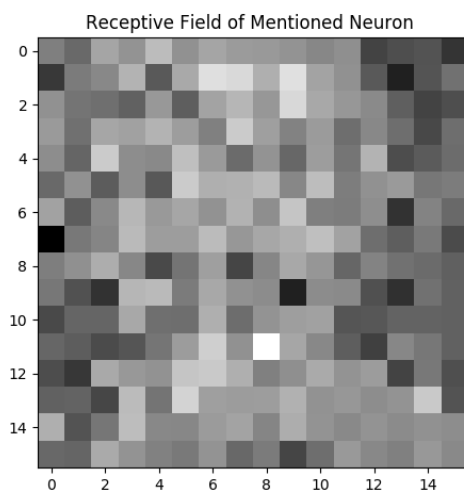


روش مورد استفاده در مقاله برای بدست آوردن راستای نورون‌ها بدین شرح است که stimuli های متفاوتی را در جهت‌های گوناگون به RF نورون مربوطه می‌تابانند و نورون در این جهت‌ها کم و یا زیاد شروع به firing می‌کند. سپس spike هایی که این نورون در هر جهت زده است، شمرده می‌شود و سپس از راستاها با وزن firing نورون در آن جهت‌ها میانگین گرفته می‌شود و راستای کدینگ نورون مشخص می‌شود.

## قسمت سوم: بررسی با روش کلاسیک Average Triggered Spike


۱.

تابع مربوطه با نام `get_spike_trigger_average` در کد پایتون مربوطه قرار دارد و کد مربوط به plot کردن آن در متن کد با کامنت مشخص شده است. خروجی تابع برای نوروں با شماره 000503 به شکل زیر است:



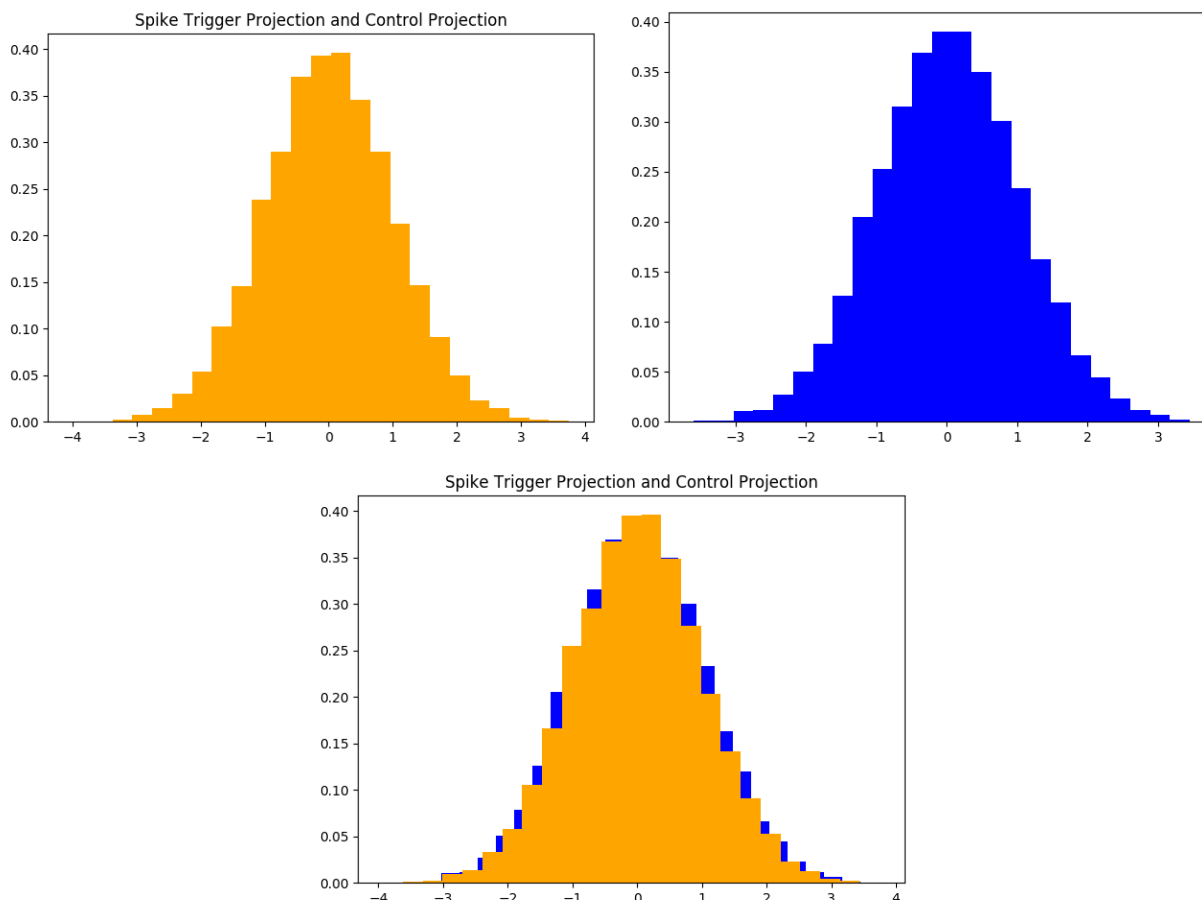
۲.

کد مربوط به این سوال در فایل پایتون، در تابعی با نام `calculate_t_test` موجود است و کد مربوط به plot کردن آن در متن کد با کامنت مشخص شده است. خروجی تابع برای نوروں با شماره 000503 به شکل زیر است:



۳.

همانطور که در قسمت الف. اشاره شد، برای بدست آوردن دیتا کنترل، از stimulus مربوط به تعداد داده‌ی trigger به صورت رندوم سمپل می‌گیریم و این دیتا و داده‌ی spike trigger را بر روی بردار با بعد ۲۵۶ STA تصویر می‌کنیم. توزیع اندازه تصویر این بردارها برای نوروں با شماره 000503 زیر است. نمودار آبی رنگ برای دیتا spike trigger است و نارنجی رنگ برای داده کنترل.



کد مربوط به این سوال در تابع `projection_on_spike_trigger_average` در فایل پایتون ضمیمه شده قرار دارد.


۰.۴

*spike trigger average :*

*t\_test\_score :* 2.720377408438099

*p-value :* 0.0065228133953695805

همانطور که در نمودارها مشخص است توزیع داده‌های رندوم و داده‌هایی که باعث spiking نورون شده‌اند بسیار به هم نزدیک است و این نزدیکی در significant نبودن p-value نیز مشهود است. این مقدار p-value این معنا را می‌دهد که انگار اگر از داده‌های رندوم نیز استفاده می‌کردیم همان مقدار firing را از نورون مربوطه می‌گرفتیم که از نورون‌هایی که می‌دانیم باعث trigger شدن می‌شود استفاده کنیم.



اگر دو توزیع گوسی خود را مانند شکل بالا در نظر بگیریم به صورتی که نمودار قرمز رنگ، توزیع تحریک‌هایی که باعث spike شده اند در نظر بگیریم و نمودار آبی توزیع داده‌های کنترل باشد، بهترین *threshold* که می‌توانیم بگذاریم جایی است که دو نمودار توزیع همدیگر را قطع می‌کنند زیرا بعد از آن احتمال اسپایک زدن تحریک‌های رندوم به شدت کاهش می‌یابد اما احتمال اینکه تحریک *trigger* سبب spike شود در حال افزایش است. حال با توجه به اینکه توزیعی که برای این دو در آزمایش بدست آوردیم تقریباً یکسان است، با اعمال *threshold* ای که در بالا بدست آوردیم، حدود 50% از مجموعه‌ی داده‌ای کنترل و *trigger* را درست تشخیص می‌دهیم که بدین معناست که 50% خطا داریم که بسیار بالاست.

در فایل پایتون فرستاده شده در متن کد پیاده سازی شده است که بدلیل زمان زیادی که برای محاسبه مقادیر خواسته شده نیاز دارد، کامنت شده است.

با توجه به نتایجی که در قسمت‌های ۴ و ۵ این بخش بدست آوردیم می‌توان گفت هیچ فرقی در داده‌هایی که رندوم بدست آمده و داده‌هایی که واقعا باعث *spiking* نوروں می‌شود وجود ندارد و هر دو ویژگی‌های یکسانی را از *firing* نوروں به ما می‌دهد که می‌دانیم این در واقعیت درست نیست. پس در این جا روش آنالیز داده‌ای که استفاده کرده‌ایم مورد بحث است بدین معنا که خروجی این روش که همان بردار *STA* است و ویژگی بینایی نوروں موردنظر را مشخص می‌کند برای دنباله تحریک‌هایی که در واقعیت باعث spike زدن نوروں می‌شوند و تحریک‌هایی که به صورت رندوم بدست آمده‌اند هیچ تفاوتی قائل نیست و جفت این دنباله‌ها نتیجه یکسانی می‌دهند. از نتایج بدست آمده می‌توان استدلال کرد که روش *spike trigger average* روش مناسبی برای مدل کردن نوروں‌ها نیست یا به عبارتی دیگر این مدل نمی‌تواند رابطه‌ی بین تحریک و پاسخ را برای نوروں‌های پیچیده در سیستم بینایی به درستی کد کند.


## قسمت چهارم: بررسی با روش *Correlation Spike-triggered*

کد مربوط به این بخش در تابع *spike\_triggered\_correlation* در فایل پایتون فرستاده شده، قرار دارد. همچنین بدست آوردن بردار و مقادیر ویژه نیز در متن کد زده شده است.


۳ بردار ویژه بدست آمده برای response اول نوروں با شماره 000503 به شکل زیر بدست آمد:

code of neuron : 000503

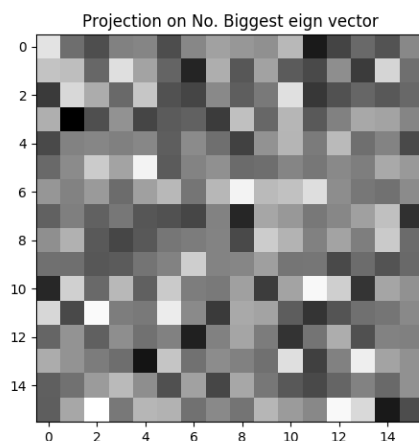
event : [5.4200e + 02, 6.9400e + 02, 1.6570e + 03, ..., 1.7123e + 06, 1.7125e + 06, 1.7137e + 06]



(ب) بردار ویژه مربوط به  $\lambda_2$



(آ) بردار ویژه مربوط به بزرگترین مقدار ویژه ( $\lambda_1$ )



(ج) بردار ویژه مربوط به  $\lambda_3$

۰.۲


۰.۳

همانند روشی که در بالا بحث کردیم، داده‌های کنترل را برای هر دو بردار ویژه تولید می‌کنیم و توزیع تصویر داده‌های trigger و کنترل را بر روی این دو بردار بدست می‌آوریم، برای نوروں با اطلاعات زیر دو نموداری که در ادامه بیان می‌شود، بدست آمد.


code of neuron : 000503

event : [5.4200e + 02, 6.9400e + 02, 1.6570e + 03, ..., 1.7123e + 06, 1.7125e + 06, 1.7137e + 06]





(ب) توزیع تصویر داده‌ها بر روی بردار ویژه دوم



(آ) توزیع تصویر داده‌ها بر روی بردار ویژه اول

همانطور که در نمودارهای بالا می‌بینیم، بین توزیع‌های داده کنترل و داده‌های trigger که بر روی بردارهای ویژه که همان feature های بینایی هستند، تفاوت معنادار تری نسبت به روش STA دیده می‌شود که بدین معناست که روش correlation spike trigger در مدل کردن رابطه‌ی بین تحریک و پاسخ در نورون‌های پیچیده موفق‌تر است نسبت به روش STA که در قبل بیان کردیم.